

SportsStats Analytics : Rapport de Consulting Premium – 120 ans de Données Olympiques

1. Page de Couverture

SportsStats Analytics


End-to-End Olympic Data Analytics Report

L'excellence décisionnelle par la donnée historique : De la donnée brute aux insights actionnables.

Préparé par : Al Ousseimine SOULEMANE

Date: 19/07/2026

Workflow Projet:



2. Sommaire

1. [Executive Summary](#)
2. [Contexte Business et Objectifs du Projet](#)
3. [Vue d'Ensemble du Dataset et Diagnostic Qualité](#)
4. [Architecture de la Solution et Stack Technique](#)
5. [Ingénierie de la Donnée et Feature Engineering](#)
6. [Analyses Stratégiques SQL](#)
7. [Dashboard Executive : Pilotage Global](#)
8. [Dashboard Country Performance : Analyse de Compétitivité](#)
9. [Recommandations Business et Stratégie de Croissance](#)
10. [Gestion des Risques et Leçons Apprises](#)
11. [Profil de l'auteur](#)
12. [Conclusion](#)

3. Executive Summary

Ce rapport présente la transformation de 120 ans d'archives olympiques en une solution analytique.

Conclusions Stratégiques :

- Les États-Unis dominent le classement historique des médailles.
- Les délégations plus petites comme le Kenya obtiennent une efficacité médaille plus élevée.
- Michael Phelps est l'olympien le plus décoré.
- L'athlétisme et la natation concentrent le plus grand nombre de médailles.
- La participation aux Jeux olympiques a augmenté régulièrement au cours du siècle dernier

4. Contexte Business et Objectifs du Projet

Le client SportsStats souhaite produire des analyses permettant aux journalistes sportifs et aux entraîneurs d'identifier les tendances marquantes des Jeux Olympiques à partir de plus de 120 ans de données.

Objectifs :

1. Quels pays ont remporté le plus grand nombre de médailles olympiques tout au long de l'histoire des Jeux olympiques ?

2. Quelle est la répartition des médailles d'or, d'argent et de bronze pour chaque pays ?
3. Quels pays ont le taux de médailles le plus élevé en fonction du nombre d'athlètes qu'ils ont envoyés aux Jeux olympiques ?
4. Quels athlètes sont les plus médaillés de l'histoire olympique ? Quels sports ont la plus grande concentration de médailles, et comment cela varie-t-il selon le genre ?
5. Comment la participation aux Jeux olympiques et la répartition des médailles ont-elles évolué au fil du temps ?

5. Vue d'Ensemble du Dataset et Diagnostic Qualité

Le socle de données est composé de deux tables pivots :

1. **athlete_events** (271 116 lignes) : Historique granulaire des participations.
2. **noc_regions** (230 lignes) : Référentiel géographique pour la cartographie des performances.

Diagnostic de Qualité et Intégrité

1. L'audit des données a révélé une fragmentation significative, caractéristique des archives historiques.
2. La détection d'anomalies a identifié 8 athlètes de plus de 80 ans. Cette rigueur statistique permet de distinguer les performances athlétiques extrêmes des bruits de données.

6. Architecture de la Solution et Stack Technique

L'architecture repose sur un pipeline de données moderne garantissant la traçabilité de l'information (Data Lineage) :

1. **Ingestion** : Chargement des fichiers CSV bruts.
2. **Transformation**: nettoyage Databricks (SQL), conversion des types et correction de la casse (ex: 15 890 corrections sur 'City').
3. **Analytics** : Création de vw_olympics_analytics, la vue SQL consolidée agissant comme **Single Source of Truth** .

Stack Technique :

- **Databricks** : Cluster de calcul pour le traitement des 271K lignes.
- **SQL** : Pivot central pour la logique métier et les KPIs.
- **Power BI** : Couche de restitution pour le pilotage interactif.

7. Ingénierie de la Donnée et Feature Engineering

Pour transformer la donnée brute en valeur business, j'ai enrichi le dataset via des calculs avancés.

- **Calcul de l'IMC (BMI) Rigoureux** : Utilisation de la formule $\text{Weight} / \text{POWER}(\text{Height} / 100.0, 2)$ pour normaliser les unités et segmenter selon les standards OMS (Obésité, Normal, etc.).
- **Segmentation par Époques Géopolitiques** : Division historique cruciale pour comparer ce qui est comparable :
- **1896-1936** : L'ère des pionniers.
- **1948-1988** : L'ère de la Guerre Froide et de l'expansion.
- **1992-2016** : L'ère de la mondialisation.
- **Statut d'Expérience** : catégorisation des athlètes en 'Débutant', 'Experienced' ou 'Veteran' selon leur historique de participations.

8. Analyses Stratégiques SQL

1. Performance des Nations

Business Question : Quelles puissances sportives garantissent le ROI éditorial le plus élevé ?

```
SELECT COUNT(*) AS Total_Medals, Region
FROM vw_olympics_analytics
WHERE Is_Medalist = 1
GROUP BY Region ORDER BY Total_Medals DESC LIMIT 10;
```

Valeur Business : Identifie les marchés piliers. Les USA et la Russie dominent, offrant des opportunités de monétisation massives via des rétrospectives historiques.

2. Efficacité des Délégations (Cas du Kenya)

Business Question : Comment identifier l'efficience pure indépendamment de la taille du pays ?

```
-- Ratio médailles par athlète unique
WITH summary AS (
    SELECT Region, COUNT(*) AS Total_Medals FROM
vw_olympics_analytics
    WHERE Is_Medalist = 1 GROUP BY Region
),
athletes AS (
    SELECT Region, COUNT(DISTINCT ID) AS Total_Athlete FROM
vw_olympics_analytics GROUP BY Region
)
SELECT s.Region, a.Total_Athlete, s.Total_Medals,
round(s.Total_Medals * 1.0 / nullif(a.Total_Athlete, 0), 3) AS
Medals_Per_Athlete
FROM summary s JOIN athletes a ON s.Region = a.Region
ORDER BY Medals_Per_Athlete DESC LIMIT 10;
```

3. Analyse des Icônes (Michael Phelps)

Business Question : Identification des vecteurs d'engagement individuel.

```
SELECT Name, SUM(Is_Medalist) AS Total_Medals,  
SUM(CASE WHEN Medal = 'Gold' THEN 1 ELSE 0 END) AS Gold_Count  
FROM vw_olympics_analytics  
GROUP BY ID, Name ORDER BY Total_Medals DESC LIMIT 1;
```


4. Dynamiques de Participation

Business Question : Quelle est la trajectoire de croissance structurelle des Jeux ?


```
SELECT Year, count(DISTINCT ID) AS Total_Athlete, SUM(Is_Medalist)  
AS Total_Medals  
FROM vw_olympics_analytics  
GROUP BY Year ORDER BY Year;
```

Valeur Business : Permet d'anticiper les besoins logistiques et la scalabilité des outils de diffusion pour les futurs partenaires.

9. Dashboard Executive : Pilotage Global



10. Dashboard Country Performance : Analyse de Compétitivité



11. Recommandations Business et Stratégie de Croissance

1. **Architecture Cloud & Temps Réel :** Migrer vers un pipeline de données automatisé pour intégrer les résultats des prochaines éditions dès leur publication (Zero Latency).
2. **Analyses Prédictives (ML) :** Développer des modèles basés sur l'IMC, l'âge et l'expérience pour prédire les probabilités de podium lors des prochaines épreuves.
3. **Optimisation du ROI par Discipline :** Focaliser les ressources analytiques sur les sports à haute densité de médailles (Athlétisme, Natation) pour conseiller les sponsors majeurs.

12. Gestion des Risques et Leçons Apprises

- **Gestion des Doublons :** Le grain de la donnée (Participation par épreuve) a nécessité une logique d'agrégation DISTINCT sur les IDs pour ne pas surestimer le nombre d'athlètes.
- **Fiabilité Historique :** Le traitement des incohérences de casse et des valeurs manquantes a prouvé qu'une "Single Source of Truth" est indispensable pour éviter que deux analystes ne produisent des résultats contradictoires.
- **Impact Technique :** L'extraction de la logique métier (BMI, tranches d'âge) vers la couche SQL garantit que tous les outils (Power BI, rapports ad-hoc) utilisent les mêmes définitions validées.

13. Résultats du projet

Technique

- 271 116 enregistrements traités
- Couche analytique SQL créée
- Tableaux de bord interactifs construits

Business

- Tendances historiques identifiées
- Benchmarking par pays
- Efficacité des médailles mesurée

Compétences démontrées

- SQL
- Power BI
- Databricks
- Storytelling
- Conception de tableaux de bord

14. Profil de l'auteur

AI Ousseimine SOULEMANE

Core Skills

- SQL
- Power BI
- Databricks
- Data Cleaning
- Feature Engineering
- Business Intelligence
- Git
- GitHub

Currently Learning

- Python
- Tableau

Contact :

- LinkedIn: www.linkedin.com/in/alussemin
- GitHub: <https://github.com/AI-Ousseimine/SportsStats-Analytics.git>

À la recherche d'une alternance en tant que Data Analyst / Analytics Engineer

14. Conclusion

Ce rapport démontre l'avantage compétitif d'une approche analytique rigoureuse. En centralisant 120 ans de données olympiques au sein d'une architecture robuste, SportsStats passe d'une gestion réactive de l'information à une stratégie proactive basée sur la donnée. Cette solution n'est pas seulement un outil de visualisation, c'est un actif stratégique prêt pour les défis de l'olympisme moderne.